

CORE-MP: Computación Objetiva de Relaciones Exitosas mediante Modelos Predictivos. Un enfoque data-driven para la evaluación de compatibilidad.

Raúl Bernalte Sánchez

José Manuel Bastante Rodríguez

Óscar Domínguez Ocaña

José Alberto Seco Sánchez-Camacho

Dr. José Antonio De La Torre Las Heras

Dr. Julio Alberto López Gómez

Introducción	3
Hito 1: Definición del problema y determinación del alcance	5
Contexto y definición del problema	5
Objetivos generales y específicos	7
Determinación del alcance	8
Planificación	9
Recursos Humanos: asignación de tareas y capacidad	9
Delimitación funcional del sistema	11
Viabilidad y estimación del ROI	11
Valor	13
Los datos: origen, descripción y análisis	14
Introducción	14
Fuentes, origen y tamaño de los datos	14
Inventario de datos	14
Análisis de los datos	18
Distribuciones de las Variables Objetivo	18
Afinidad e Ingeniería de Características	19
Evaluación del rendimiento y Métricas	21
1. Predicción de Compatibilidad Binaria	21
2. Estimación de Longevidad Relacional	21
3. Recomendación (Matching óptimo)	22
References	23

List of Tables

1	Inventario de datos original: Diccionario de variables	16
2	Diccionario de variables interactivas: características con pesos positivos y negativos	20

List of Figures

1	Flujo metodológico del sistema CORE-MP desde la definición del problema hasta el análisis de viabilidad.	8
2	Extracto de los datos del Individuo A correspondientes a los 24 primeros emparejamientos evaluados. Se aprecian las variables demográficas y las métricas del modelo <i>Big Five</i>	17
3	Extracto de los datos del Individuo B correspondientes a los 24 primeros emparejamientos. Nótese la obligatoria correspondencia del campo <code>pair_id</code> con el Individuo A para posibilitar el emparejamiento.	17
4	Representación de las variables objetivo que definen el nivel de satisfacción y viabilidad de la relación, correspondientes a los 24 primeros registros del conjunto de datos.	18
5	Distribución de las variables objetivo: densidad del <i>score</i> de compatibilidad (izquierda), proporción de éxito binario (centro) y distribución de longevidad en meses (derecha).	19
6	Matriz de contingencia térmica (<i>Heatmap</i>): Tasa de compatibilidad porcentual según el cruce de los lenguajes del amor entre ambos individuos.	19

1

En el contexto de la **transformación digital de las relaciones interpersonales**, las plataformas de citas y aplicaciones de *matching* han adquirido un papel central en la forma en que las personas establecen conexiones afectivas. En la actualidad, estas plataformas gestionan enormes volúmenes de información sobre preferencias, rasgos de personalidad, características demográficas y patrones de comportamiento. El objetivo fundamental de este ecosistema digital es procesar dicha información para facilitar la formación de **relaciones compatibles y potencialmente duraderas**, actuando como intermediarios algorítmicos en el tejido social.

Tradicionalmente, los sistemas de recomendación en este ámbito se han basado en filtros simples, reglas heurísticas o mecanismos poco transparentes que priorizan coincidencias superficiales (como la edad, la localización geográfica o los intereses básicos). Sin embargo, la compatibilidad relacional es un **fenómeno inherentemente complejo y multidimensional**. El éxito de una relación no se define por la simple superposición de aficiones, sino que depende de una intrincada red de factores psicológicos, valores personales, estilo de vida, ambiciones profesionales y patrones emocionales. La incapacidad de los sistemas tradicionales para capturar esta profundidad suele derivar en recomendaciones irrelevantes, generando frustración y fatiga en el usuario.

En este contexto, surge la necesidad crítica de diseñar **sistemas de inteligencia artificial** capaces de modelar de forma cuantitativa y estructurada la compatibilidad entre individuos. Al integrar múltiples dimensiones personales, estos sistemas pueden descubrir patrones latentes y generar predicciones que sean **consistentes, reproducibles y explicables**. En el delicado ámbito de las relaciones humanas, un sistema de este tipo no solo debe alcanzar un alto rendimiento técnico o estadístico, sino también garantizar su interpretabilidad. Resulta imperativo mantener la coherencia con los principios del dominio relacional, evitando a toda costa funcionar como una "caja negra" que tome decisiones opacas o arbitrarias.

El presente proyecto se fundamenta en el dataset "*Cupid's Algorithm*" [Ged24], un conjunto de datos que contiene información estructurada y enriquecida sobre pares de individuos. Este *dataset* abarca desde

¹El formato y la estructura documental de esta memoria han sido desarrollados utilizando la plantilla oficial de proyectos de la ULB [Uni24].

variables demográficas y profesionales hasta métricas psicométricas profundas, como los rasgos de personalidad basados en el modelo **Big Five** [Rak+24] y los lenguajes del amor, acompañados de indicadores históricos de compatibilidad y duración potencial de la relación. La riqueza de esta información permite abordar el reto desde una **perspectiva supervisada**, formalizando la afinidad relacional como una variable matemática susceptible de ser modelada mediante técnicas avanzadas de aprendizaje automático.

A partir de este marco conceptual, el proyecto no se limita al mero entrenamiento de un modelo predictivo aislado en un entorno académico, sino que adopta una visión integral del **sistema de inteligencia artificial como producto**. Esto implica recorrer, de manera rigurosa, todas las fases del ciclo de vida de un sistema de *Machine Learning* (MLOps): desde la definición formal del problema y la preparación de los datos, pasando por el modelado y la evaluación, hasta culminar en su **integración como servicio de software** y su correspondiente análisis de viabilidad técnica y económica.

De este modo, el objetivo principal del proyecto es diseñar e implementar un **sistema inteligente** capaz de predecir la compatibilidad entre dos individuos de forma completamente objetiva y explicable. Un sistema concebido desde su inicio para ser un componente integrable en una plataforma digital de relaciones, y evaluado no solo a través de métricas de precisión técnica, sino también por su **potencial impacto organizativo, económico y social**.

Hito 1: Definición del problema y determinación del alcance

En este capítulo se detalla la definición del problema seleccionado para la evaluación del proyecto de la asignatura *Desarrollo e Integración de Servicios de IA*, así como la determinación de su alcance.

Contexto y definición del problema

En el ámbito de las plataformas digitales de relaciones interpersonales, la predicción de compatibilidad entre individuos constituye un problema de **alta relevancia tecnológica, social y económica**. Las aplicaciones de citas modernas gestionan grandes volúmenes de información estructurada sobre los usuarios, incluyendo variables demográficas, profesionales, rasgos de personalidad y preferencias relacionales. A partir de estos datos, los sistemas deben decidir qué perfiles recomendar y qué emparejamientos priorizar.

La compatibilidad relacional es, sin embargo, un **fenómeno inherentemente complejo y multidimensional**. No depende exclusivamente de variables superficiales como la edad o la localización geográfica, sino que está influida por la interacción entre rasgos de personalidad, valores personales, ambiciones profesionales, estilos de comunicación, hábitos cotidianos y expectativas afectivas. Esta naturaleza multifactorial convierte la modelización de la compatibilidad en un problema analítico no trivial.

Tradicionalmente, muchas plataformas han empleado reglas heurísticas o sistemas de filtrado simples basados en coincidencias directas. Estos enfoques presentan limitaciones evidentes, especialmente en escenarios donde las interacciones entre variables son no lineales y complejas: no capturan interacciones complejas, no aprenden patrones implícitos y carecen de transparencia. A diferencia de una regla heurística simple que podría asumir erróneamente que dos personas con la misma *ambición profesional* son compatibles, un modelo de inteligencia artificial puede descubrir **patrones latentes**. Por ejemplo, identificar que dos personas con niveles opuestos de *espontaneidad* pueden ser altamente compatibles si comparten el mismo *lenguaje del amor*. Esta capacidad de capturar interacciones no lineales justifica la necesidad de emplear algoritmos avanzados.

El dataset seleccionado para este proyecto, “*Cupid’s Algorithm*” [Ged24], contiene información estructurada sobre pares de individuos (Person A – Person B), incluyendo:

- **Variables demográficas** (edad, nivel educativo, localización).

- **Variables profesionales** (campo profesional, nivel de ambición).
- **Rasgos de personalidad** basados en el modelo *Big Five*.
- **Variables relacionales** (lenguaje del amor, cronotipo, espontaneidad, expresividad emocional).
- Una variable continua de compatibilidad (*compatibility_score*).
- Una variable binaria de compatibilidad (*compatible*).
- Un indicador de longevidad relacional (*relationship_longe*).

La presencia de estas variables permite abordar el problema desde una **perspectiva supervisada**, donde la compatibilidad observada actúa como señal objetivo para el aprendizaje.

Desde el punto de vista formal, el problema puede plantearse como un problema de **clasificación binaria** [Gér19]. Cada par de individuos queda caracterizado por un conjunto de variables numéricas y categóricas que describen sus atributos individuales.

Sea $X \in \mathbb{R}^n$ el vector de características construido a partir de las variables de ambos individuos. El sistema debe aprender una función parametrizada:

$$f_{\theta} : \mathbb{R}^n \rightarrow [0, 1]$$

tal que:

$$\hat{y} = f_{\theta}(X) = P(Y = 1 | X)$$

donde $Y = 1$ indica compatibilidad entre los individuos.

De este modo, el modelo estima la probabilidad de que un determinado par de individuos sea compatible, en función de las interacciones existentes entre sus características demográficas, profesionales y psicológicas.

Alternativamente, el problema puede formularse como una regresión (utilizando *compatibility_score*) o como una predicción de duración (empleando *relationship_longe*). No obstante, en este proyecto se delimita el alcance principal al problema de clasificación binaria, al tratarse de una formulación clara, evaluable y directamente alineada con aplicaciones reales de *matching*.

El sistema no debe limitarse a generar una predicción numérica, sino que debe concebirse como un **sistema de inteligencia artificial integrable** en un entorno software real. Esto implica que el modelo debe ser reproducible, evaluable mediante métricas adecuadas y *explicable*, dado que en sistemas que influyen en decisiones sociales la interpretabilidad resulta fundamental para evitar modelos opacos o de tipo “caja negra”

En consecuencia, el problema queda claramente delimitado: a partir de datos estructurados que describen características personales, profesionales y psicológicas de dos individuos, se busca diseñar un sistema de inteligencia artificial capaz de predecir de forma **objetiva, consistente y explicable** su compatibilidad relacional, concebido como un componente integrable dentro de una arquitectura software más amplia.

Objetivos generales y específicos

El problema que se aborda en este proyecto puede formularse de la siguiente manera: ¿Cómo diseñar un sistema de inteligencia artificial capaz de predecir de forma objetiva, consistente y explicable la compatibilidad entre dos individuos, a partir de variables demográficas, profesionales y de personalidad, garantizando su integración como servicio software en una plataforma digital de relaciones?

Esta formulación no se limita a la obtención de buenas métricas técnicas, sino que incorpora explícitamente la dimensión de **sistema IA como producto**, concebido para integrarse en un entorno real, evolucionar en el tiempo y aportar valor a distintos *stakeholders*.

Para dar respuesta a esta pregunta, se establece como **objetivo general** del proyecto diseñar, implementar y validar un sistema de inteligencia artificial capaz de predecir la compatibilidad relacional entre dos individuos utilizando datos estructurados, garantizando su integración en una arquitectura software real y su funcionamiento fiable, explicable y reproducible a lo largo del tiempo.

Para alcanzar el objetivo general propuesto, se establecen los siguientes **objetivos específicos**:

- **Analizar y formalizar** el concepto de compatibilidad relacional desde una perspectiva cuantitativa y multidimensional, identificando las variables más relevantes.
- **Seleccionar y procesar** los datos del dataset *Cupid's Algorithm*, incluyendo limpieza, codificación y construcción de variables derivadas (similitud o distancia entre perfiles).
- **Diseñar y entrenar** modelos de aprendizaje automático supervisado que permitan predecir la variable binaria compatible, evaluando distintas aproximaciones metodológicas.
- **Evaluar el rendimiento** de los modelos mediante métricas técnicas adecuadas para clasificación binaria (Accuracy, Precision, Recall, F1-score, ROC-AUC), analizando su comportamiento desde una perspectiva de dominio.
- **Incorporar mecanismos de explicabilidad**, que permitan interpretar la influencia relativa de las distintas variables y facilitar su comprensión por parte de perfiles no técnicos.

- **Diseñar el sistema como un servicio integrable**, desarrollando una API REST que permita realizar predicciones de compatibilidad a partir de nuevos pares de individuos.
- **Analizar la viabilidad** económica y organizativa del sistema, estimando costes de desarrollo y potencial retorno de la inversión (ROI).
- **Diseñar el sistema con una arquitectura extensible** que permita, en iteraciones futuras, transicionar de una clasificación binaria a un motor de recomendación Top-K o a la predicción de longevidad relacional.

De este modo, el proyecto no se concibe como un simple ejercicio de modelado predictivo, sino como el desarrollo completo de un **sistema de inteligencia artificial entendido como producto tecnológico**, recorriendo todas las fases de su ciclo de vida.

La Figura 1 resume el flujo metodológico seguido en el desarrollo del sistema CORE-MP.



Figure 1: Flujo metodológico del sistema CORE-MP desde la definición del problema hasta el análisis de viabilidad.

Determinación del alcance

En esta sección se define el alcance del proyecto a desarrollar en la asignatura, prestando especial atención a los componentes clave que delimitan un sistema de inteligencia artificial concebido como producto: **planificación temporal, organización del equipo, viabilidad económica y valor generado.**

El alcance no solo determina qué se va a desarrollar, sino también qué queda explícitamente fuera del proyecto, con el fin de garantizar su viabilidad dentro del marco temporal y evitar una expansión descontrolada de requisitos.

Planificación

El desarrollo del proyecto se ha estructurado en un horizonte temporal estimado de **ocho semanas**, concebido como un flujo de trabajo continuo que abarca todas las fases del ciclo de vida de un sistema de *Machine Learning*. Durante las dos primeras semanas, el equipo se centrará en el **análisis y comprensión del problema**. Esta fase inicial es crítica e implica un estudio detallado del dataset *Cupid's Algorithm*, la realización de un análisis exploratorio de las variables disponibles y la formalización definitiva del reto como un problema de clasificación binaria.

A continuación, las semanas tercera y cuarta se destinarán a la **preparación y transformación de los datos**. En este periodo se llevarán a cabo tareas fundamentales como la limpieza del conjunto de datos, el tratamiento de valores nulos, la codificación de las variables categóricas y, de forma muy destacada, la ingeniería de características para construir variables derivadas que representen similitudes, diferencias y distancias entre los perfiles. Esta fase concluirá con la división técnica del dataset en conjuntos de entrenamiento y validación.

Posteriormente, el proyecto entrará en su núcleo analítico durante las semanas quinta y sexta, enfocadas en el **modelado y la evaluación**. Durante esta etapa, se entrenarán distintos modelos de aprendizaje supervisado, se compararán sus métricas de rendimiento y se seleccionará el modelo final. Además, se dedicará un esfuerzo específico al análisis de la explicabilidad del sistema, garantizando que las predicciones no provengan de una caja negra. Una vez consolidado el modelo, la séptima semana marcará la transición hacia la **integración como servicio**. El equipo procederá a la serialización del modelo entrenado y al desarrollo de una API REST que permita realizar predicciones en tiempo real, finalizando con pruebas funcionales del sistema.

Finalmente, la octava semana estará dedicada a la **validación y el análisis de valor**. En esta última etapa se evaluará el sistema en su conjunto, se realizará el análisis de viabilidad económica y retorno de inversión (ROI), y se consolidará la redacción de la documentación final del proyecto, asegurando que el producto técnico cumpla con los estándares académicos y profesionales exigidos.

Recursos Humanos: asignación de tareas y capacidad

El desarrollo del sistema **CORE-MP** se lleva a cabo mediante la colaboración de un equipo técnico formado por cuatro integrantes. Para garantizar el éxito del proyecto y simular un entorno profesional realista, se han definido perfiles con responsabilidades claramente delimitadas, alineadas con los roles habituales en el desarrollo de productos basados en inteligencia artificial.

Óscar Domínguez Ocaña. Rol principal: Product Manager y Analista de Negocio. Dado que el equipo no cuenta de forma nativa con un experto de dominio puro en psicología relacional, este integrante asume un rol híbrido fundamental. Su responsabilidad es actuar como puente entre el desarrollo técnico y los objetivos funcionales del proyecto. Se encarga de comprender a fondo la naturaleza de los datos disponibles, definir qué variables tienen sentido lógico agrupar o comparar, y establecer los umbrales de éxito del sistema. Además, evalúa si los resultados del modelo y su explicabilidad son coherentes y aportan valor real para una hipotética plataforma de *matching*, validando el producto desde la perspectiva del usuario final.

José Alberto Seco Sánchez-Camacho. Rol principal: Analista de Datos (Data Analyst / Data Engineer). Este integrante asume la responsabilidad crítica del procesamiento, limpieza y transformación de los datos procedentes del dataset original. Su trabajo abarca desde la exploración estadística inicial hasta la generación de un conjunto de datos consistente y estructurado, aplicando técnicas de ingeniería de características para crear métricas de similitud entre los perfiles. Este rol es la base sobre la que se asienta todo el proyecto, ya que la calidad de las predicciones dependerá directamente de la robustez de los datos preparados en esta fase.

José Manuel Bastante Rodríguez. Rol principal: Ingeniero de Machine Learning (ML Engineer). Este perfil es el responsable del diseño metodológico del sistema desde el punto de vista del modelado predictivo. Sus tareas incluyen la selección de los algoritmos de clasificación más adecuados, el entrenamiento de los modelos, el ajuste de hiperparámetros y la evaluación exhaustiva mediante métricas técnicas (como F1-Score o ROC-AUC). Asimismo, asume la responsabilidad de aplicar técnicas de interpretabilidad al modelo seleccionado, facilitando que el resto del equipo comprenda cómo interactúan los rasgos de personalidad en las predicciones finales.

Raul Bernalte Sánchez. Rol principal: Ingeniero de Integración y MLOps (ML Systems Engineer). Su responsabilidad principal es garantizar que el proyecto no se limite a un experimento aislado en un cuaderno de programación, sino que se convierta en un producto de software funcional. Sus labores incluyen la serialización y versionado del modelo entrenado, así como el diseño y desarrollo de la API REST que servirá las predicciones. Este integrante se asegura de que la arquitectura del sistema sea robusta y esté preparada para recibir peticiones de emparejamiento como un microservicio independiente.

Esta estructura organizativa garantiza que se cubran todas las necesidades del ciclo de vida de un sistema de IA concebido como producto, desde la conceptualización del negocio hasta su despliegue técnico.

Delimitación funcional del sistema

El sistema CORE-MP se limita funcionalmente al desarrollo de un modelo de clasificación binaria capaz de predecir la variable (*compatible*) a partir de las características estructuradas de dos individuos. El alcance del sistema contempla exclusivamente el uso del dataset *Cupid's Algorithm* como fuente de datos, sin integración con bases de datos externas ni incorporación de datos en tiempo real.

El sistema será desplegado como un servicio REST académico que permita realizar predicciones a partir de nuevas entradas estructuradas. La evaluación del modelo se realizará en entorno *offline* mediante métricas estándar de clasificación, sin validación en una plataforma real de usuarios.

Quedan explícitamente fuera del alcance:

- Desarrollo de una plataforma web completa o integración con bases de datos reales en producción.
- Implementación de un sistema de recomendación Top-K a gran escala.
- Despliegue en entorno *cloud* productivo final.

Viabilidad y estimación del ROI

Además de evaluar el rendimiento técnico del sistema, resulta necesario analizar si el desarrollo de la solución propuesta puede generar un valor suficiente como para justificar los recursos invertidos en su implementación. En proyectos de inteligencia artificial aplicados a productos digitales, esta evaluación suele realizarse mediante una estimación aproximada del retorno de la inversión (*Return on Investment*, ROI).

Dado que el presente proyecto se desarrolla en un contexto académico y no se dispone de información económica real de una empresa concreta, el análisis se realiza utilizando supuestos razonables que permiten aproximar el orden de magnitud de los costes y beneficios potenciales.

Para estimar el coste de desarrollo del sistema CORE-MP se consideran los siguientes parámetros:

- Tamaño del equipo de desarrollo: 4 personas.
- Dedicación media por integrante: 5 horas semanales.
- Duración del proyecto: 12 semanas.
- Coste medio estimado por hora de trabajo técnico: 40 euros.

A partir de estos valores se puede estimar el esfuerzo total invertido en el proyecto:

$$\text{Horas totales} = 4 \times 5 \times 12 = 240 \text{ horas}$$

$$\text{Coste total} = 240 \times 40 = 9.600 \text{ euros}$$

Este coste engloba las diferentes fases del desarrollo del sistema: análisis del problema, exploración y preparación del conjunto de datos, diseño y entrenamiento de los modelos de aprendizaje automático, evaluación de resultados, análisis de explicabilidad y desarrollo del servicio REST que permite integrar el sistema en una arquitectura software.

En cuanto a los beneficios potenciales, el sistema CORE-MP podría aportar valor a una plataforma digital de relaciones en distintos niveles. Entre los principales beneficios se pueden destacar:

- Mejora de la calidad de las recomendaciones de emparejamiento.
- Incremento potencial de la satisfacción y retención de usuarios.
- Automatización del análisis de compatibilidad entre perfiles.
- Posibilidad de reutilizar el sistema como base para futuros motores de recomendación más avanzados.
- Generación de valor estratégico al incorporar capacidades de inteligencia artificial en la plataforma.

Para estimar el beneficio económico de forma conservadora, se considera un escenario hipotético en el que la mejora en la calidad de los emparejamientos incrementa la retención de usuarios de la plataforma. Suponiendo una plataforma con aproximadamente 2.000 usuarios activos y un ingreso medio anual de 10 euros por usuario, una mejora del 10% en la retención podría generar alrededor de 2.000 euros adicionales al año.

Si el sistema se reutiliza durante varios ciclos del producto, el valor acumulado podría situarse en torno a 10.000 euros. Considerando además el valor tecnológico derivado de reutilizar el sistema como base para futuros servicios de recomendación, se puede estimar de forma conservadora un beneficio total aproximado de 13.000 euros.

Con estos valores, el retorno de la inversión se calcula como:

$$ROI = \frac{\text{Beneficio} - \text{Coste}}{\text{Coste}}$$

$$ROI = \frac{13000 - 9600}{9600} = 0.35$$

Es decir, un retorno aproximado del **35%**.

Este resultado indica que, incluso bajo supuestos conservadores, el sistema CORE-MP podría recuperar la inversión inicial y generar valor adicional. Además, este cálculo no contempla posibles beneficios adicionales como la comercialización del sistema, la ampliación de funcionalidades o su reutilización en otros contextos de recomendación, lo que sugiere que el valor real del sistema podría ser aún mayor.

Valor

El valor del sistema **CORE-MP** se analiza desde múltiples dimensiones:

- **Valor de Negocio / Relacional:** Generación de emparejamientos de alta calidad que justifican modelos de suscripción *Premium* y reducen la fatiga del usuario (*swipe burnout*), aumentando el ciclo de vida del cliente.
- **Valor tecnológico:** Formalización de la compatibilidad como problema supervisado mediante un modelo reproducible, explicable y con arquitectura de microservicio.
- **Valor organizativo:** Sistema escalable que sienta las bases para futuros motores de recomendación más avanzados.
- **Valor social:** Mayor transparencia en el proceso de *matching*, reducción de sesgos o decisiones arbitrarias y mejora sustancial en la confianza del usuario.

Con esta delimitación, el proyecto se concibe como el desarrollo completo de un sistema de inteligencia artificial entendido como producto tecnológico, garantizando su viabilidad dentro del marco académico.

Introducción

En este capítulo se detalla el conjunto de datos utilizado para el desarrollo e integración del sistema de Inteligencia Artificial del proyecto *Cupid Algorithm*. A diferencia de los problemas de clasificación tradicional, donde se perfila a un individuo de forma aislada, el presente reto analítico requiere el estudio de una **diada** (la pareja concebida como unidad matemática).

El objetivo principal de esta sección es comprender cómo interactúan y se correlacionan los perfiles psicológicos y demográficos, establecer las métricas formales de éxito y definir los procesos de transformación de datos (*Feature Engineering*) necesarios para alimentar el modelo predictivo. Durante el desarrollo del análisis se abordará el debate psicológico subyacente sobre si la afinidad relacional se fundamenta en la complementariedad (polos opuestos) o en la homofilia (similitud), justificando empíricamente las decisiones algorítmicas adoptadas.

Fuentes, origen y tamaño de los datos

La fuente de información para realizar esta investigación es `cupid_algorithm_dataset.csv`. Este *dataset* emula el entorno operativo de una aplicación de emparejamiento (*matchmaking*) a gran escala, registrando interacciones reales entre usuarios.

En términos de volumetría, la muestra consta de **100.000 observaciones** (pares evaluados) y 30 características originales. La magnitud y completitud del conjunto de datos garantizan la representatividad estadística necesaria para entrenar modelos de aprendizaje automático de alta complejidad, mitigando el riesgo de sobreajuste (*overfitting*) temprano. Asimismo, la validación de calidad del dato evidenció una estructura robusta: la inspección inicial confirmó la ausencia total de valores nulos o faltantes, lo cual permite prescindir de técnicas de imputación sintética que pudieran introducir sesgos artificiales en las distribuciones originales.

Inventario de datos

La base de datos presenta una arquitectura simétrica, registrando idéntica batería de atributos tanto para el “Individuo A” como para el “Individuo B” de cada emparejamiento. Estas variables se agrupan formalmente

en las siguientes dimensiones:

- **Dimensión Demográfica y Sociológica:** Contiene atributos descriptivos tales como la edad, el nivel educativo (modelado como variable ordinal), la ubicación geográfica o entorno de residencia (*location*) y el campo profesional o sector productivo al que pertenecen (*career_field*).
- **Dimensión Psicológica y Conductual:** Agrupa valores normalizados en el rango [0, 1] que cuantifican la ambición profesional, la expresividad emocional, la espontaneidad y el cronotipo de cada sujeto. Resulta especialmente relevante la inclusión del modelo de los Cinco Grandes (*Big Five*): apertura a la experiencia (*openness*), extraversión, amabilidad (*agreeableness*) y responsabilidad (*conscientiousness*). Adicionalmente, se tipifica el estilo afectivo de los individuos mediante su lenguaje del amor principal.
- **Variables Objetivo (*Targets*):** Representan la verdad terreno (*ground truth*) con la que se evaluará el desempeño del sistema:
 - *compatibility_score*: Puntuación continua que evalúa la calidad y viabilidad general del emparejamiento (problema de regresión).
 - *compatible*: Etiqueta binaria de clasificación donde se codifica el éxito (1) o el fracaso (0) de la relación.
 - *relationship_longevity_months*: Duración efectiva de la relación expresada en meses.

Para facilitar la comprensión global de la estructura base del sistema, la Tabla 1 detalla el diccionario de datos original. Se listan las variables de manera genérica, asumiendo que el modelo procesa las características tanto del individuo A (*a_**) como del individuo B (*b_**).

Variable	Tipo	Descripción
pair_id	Entero	Identificador único (1 a 100,000) de cada pareja evaluada. Actúa como clave primaria.
age	Numérica	Edad cronológica (18-55). Se emplea para calcular la brecha de edad; diferencias superiores a 15 años penalizan el <i>score</i> .
education	Ordinal	Nivel educativo (1: Secundaria - 5: Doctorado). Correlaciona positivamente con la ambición profesional.
location	Categórica	Entorno de residencia (Urbano, Suburbano, Rural). Las coincidencias suman positivamente al evaluar la proximidad.
career_field	Categórica	Sector profesional (10 industrias). Su compatibilidad cruzada se evalúa internamente mediante una matriz de sinergia.
career_ambition	Num. [0,1]	Impulso de crecimiento profesional. La proximidad de valores entre la pareja indica alineación de proyectos de vida.
openness	Num. [0,1]	Rasgo <i>Big Five</i> : apertura a la experiencia, ideas nuevas y creatividad.
extraversion	Num. [0,1]	Rasgo <i>Big Five</i> : nivel de extroversión, sociabilidad, energía y asertividad social.
agreeableness	Num. [0,1]	Rasgo <i>Big Five</i> : amabilidad, tendencia a la compasión, empatía y voluntad de compromiso.
conscientiousness	Num. [0,1]	Rasgo <i>Big Five</i> : nivel de organización, disciplina y responsabilidad personal.
chronotype	Num. [0,1]	Preferencia de estilo de vida que abarca desde perfiles nocturnos hasta matutinos.
spontaneity	Num. [0,1]	Orientación vital entre la planificación estructurada (0) y el espíritu libre (1).
emotional_express...	Num. [0,1]	Estilo de comunicación: facilidad y franqueza al expresar y compartir sentimientos íntimos.
love_language	Categórica	Lenguaje del amor principal (Palabras de afirmación, Actos de servicio, Regalos, Tiempo de calidad o Contacto físico).
compatibility_score	Continua	Target: Puntuación predictiva agregada (0-100) que determina la compatibilidad base de la pareja.
compatible	Binaria	Target: Éxito relacional (1) o fracaso (0). Umbral original establecido en >65 de <i>score</i> .
relationship_lon...	Entero	Target: Longevidad de la relación expresada en meses (0-120). Útil para problemas de regresión o supervivencia.

Table 1: Inventario de datos original: Diccionario de variables

Para ilustrar de forma tangible esta arquitectura simétrica, las Figuras 2 y 3 muestran, de manera independiente, los perfiles de los usuarios vinculados que conforman los primeros 24 registros del conjunto de datos. Como se puede observar, ambos sujetos (Individuo A e Individuo B) mantienen de forma estricta el mismo identificador de pareja (*pair_id*). Esta restricción relacional es la que permite al sistema procesar la interacción de ambos como una unidad indisoluble a la hora de realizar la inferencia.

	A	B	C	D	E	F	G	H	I	J	K	L	M	N
1	pair_id	a_age	a_education	a_location	a_career_field	a_career_ambition	a_openness	a_extraversion	a_agreeableness	a_conscientiousness	a_chronotype	a_spontaneity	a_love_language	a_emotional_expressiveness
2	1	46	3	Suburban	Healthcare	0.23	0.67	0.78	0.32	0.49	0.02	0.38	Receiving Gifts	0.59
3	2	32	2	Suburban	Tech	0.58	0.78	0.7	0.51	0.71	0.43	0.72	Quality Time	0.73
4	3	25	4	Rural	Marketing	0.59	0.33	0.87	0.64	0.82	0.5	0.57	Acts of Service	0.69
5	4	38	4	Suburban	Finance	0.54	0.34	0.28	0.72	0.81	0.43	0.6	Physical Touch	0.47
6	5	36	2	Rural	Entrepreneurship	0.56	0.35	0.62	0.27	0.73	0.32	0.63	Acts of Service	0.44
7	6	40	3	Urban	Science	0.75	0.45	0.4	0.71	0.54	0.26	0.24	Words of Affirmation	0.77
8	7	28	1	Suburban	Tech	0.36	0.47	0.84	0.56	0.49	0.61	0.91	Quality Time	0.76
9	8	28	1	Suburban	Engineering	0.0	0.28	0.33	0.95	0.76	0.18	0.15	Quality Time	0.47
10	9	41	4	Urban	Entrepreneurship	0.52	0.69	0.5	0.25	0.34	0.15	0.59	Words of Affirmation	0.33
11	10	53	5	Rural	Law	0.75	0.65	0.61	0.49	0.28	0.41	0.51	Words of Affirmation	0.71
12	11	41	2	Urban	Finance	0.39	0.15	0.46	0.85	0.89	0.52	0.02	Words of Affirmation	0.83
13	12	20	3	Suburban	Creative Arts	0.39	0.16	0.18	0.32	0.53	0.36	0.71	Acts of Service	0.73
14	13	39	4	Urban	Creative Arts	0.81	0.61	0.59	0.39	0.35	0.69	0.76	Receiving Gifts	0.23
15	14	19	4	Urban	Engineering	0.65	0.46	0.41	0.15	0.85	0.42	0.73	Quality Time	0.75
16	15	41	3	Urban	Education	0.22	0.6	0.2	0.26	0.64	0.6	0.83	Receiving Gifts	0.71
17	16	47	3	Suburban	Law	0.77	0.75	0.15	0.63	0.68	0.62	0.33	Receiving Gifts	0.04
18	17	55	3	Suburban	Entrepreneurship	0.17	0.24	0.6	0.24	0.3	0.89	0.81	Words of Affirmation	0.68
19	18	19	2	Urban	Healthcare	0.28	0.37	0.89	0.22	0.42	0.53	0.43	Acts of Service	0.25
20	19	38	3	Urban	Engineering	0.42	0.69	0.54	0.43	0.41	0.32	0.6	Words of Affirmation	0.65
21	20	50	3	Urban	Law	0.52	0.48	0.73	0.19	0.59	0.93	0.82	Words of Affirmation	0.4
22	21	29	3	Urban	Entrepreneurship	0.69	0.73	0.25	0.86	0.2	0.77	0.56	Quality Time	0.47
23	22	39	2	Urban	Healthcare	0.29	0.5	0.83	0.67	0.25	0.41	0.55	Receiving Gifts	0.81
24	23	42	3	Urban	Marketing	0.55	0.31	0.54	0.21	0.36	0.67	0.94	Physical Touch	0.39
25	24	44	2	Rural	Science	0.3	0.32	0.19	0.5	0.63	0.22	0.6	Receiving Gifts	0.62
26	25	45	4	Urban	Education	0.59	0.32	0.54	0.42	0.25	0.78	0.62	Acts of Service	0.52

Figure 2: Extracto de los datos del Individuo A correspondientes a los 24 primeros emparejamientos evaluados. Se aprecian las variables demográficas y las métricas del modelo *Big Five*.

	A	O	P	Q	R	S	T	U	V	W	X	Y	Z	AA
1	pair_id	b_age	b_education	b_location	b_career_field	b_career_ambition	b_openness	b_extraversion	b_agreeableness	b_conscientiousness	b_chronotype	b_spontaneity	b_love_language	b_emotional_expressiveness
2	1	20	3	Urban	Law	0.77	0.35	0.61	0.57	0.5	0.2	0.19	Quality Time	0.73
3	2	38	1	Urban	Law	0.44	0.71	0.31	0.2	0.57	0.45	0.56	Physical Touch	0.84
4	3	46	2	Rural	Finance	0.61	0.28	0.3	0.49	0.43	0.84	0.74	Physical Touch	0.48
5	4	20	2	Urban	Science	0.39	0.47	0.35	0.46	0.21	0.8	0.35	Receiving Gifts	0.41
6	5	22	3	Urban	Creative Arts	0.63	0.44	0.66	0.45	0.43	0.86	0.36	Acts of Service	0.5
7	6	41	2	Suburban	Education	0.68	0.56	0.12	0.36	0.04	0.14	1.0	Receiving Gifts	0.83
8	7	26	3	Rural	Science	0.58	0.61	0.26	0.26	0.49	0.36	0.43	Acts of Service	0.43
9	8	21	3	Urban	Marketing	0.62	0.58	0.73	0.4	0.42	0.62	0.71	Acts of Service	0.75
10	9	38	3	Rural	Finance	0.8	0.65	0.58	0.32	0.5	0.51	0.6	Words of Affirmation	0.86
11	10	36	4	Urban	Law	0.42	0.56	0.61	0.43	0.63	0.37	0.95	Physical Touch	0.32
12	11	34	4	Suburban	Education	0.29	0.2	0.1	0.2	0.68	0.45	0.44	Quality Time	0.69
13	12	55	3	Urban	Finance	0.57	0.31	0.14	0.13	0.68	0.22	0.53	Words of Affirmation	0.8
14	13	33	2	Urban	Healthcare	0.4	0.68	0.39	0.76	0.52	0.92	0.13	Acts of Service	0.19
15	14	51	1	Suburban	Marketing	0.26	0.33	0.7	0.55	0.25	0.66	0.14	Receiving Gifts	0.6
16	15	24	5	Suburban	Tech	0.69	0.88	0.15	0.09	0.23	0.66	0.17	Quality Time	0.62
17	16	35	2	Suburban	Science	0.48	0.89	0.22	0.97	0.07	0.62	0.49	Receiving Gifts	0.42
18	17	26	4	Urban	Marketing	0.72	0.56	0.62	0.06	0.34	0.35	0.74	Acts of Service	0.78
19	18	33	2	Urban	Law	0.26	0.72	0.27	0.53	0.25	0.29	0.42	Quality Time	0.31
20	19	25	3	Suburban	Healthcare	0.21	0.24	0.22	0.78	0.36	0.75	0.52	Words of Affirmation	0.85
21	20	52	3	Suburban	Creative Arts	0.46	0.37	0.52	0.23	0.07	0.69	0.93	Physical Touch	0.41
22	21	32	3	Suburban	Tech	0.18	0.34	0.28	0.67	0.36	0.46	0.19	Acts of Service	0.15
23	22	47	4	Urban	Law	0.5	0.66	0.6	0.34	0.67	0.75	0.25	Physical Touch	0.25
24	23	45	4	Suburban	Tech	0.57	0.32	0.56	0.27	0.8	0.76	0.06	Acts of Service	0.37
25	24	34	3	Urban	Marketing	0.26	0.58	0.64	0.26	0.69	0.62	0.6	Acts of Service	0.35

Figure 3: Extracto de los datos del Individuo B correspondientes a los 24 primeros emparejamientos. Nótese la obligatoria correspondencia del campo `pair_id` con el Individuo A para posibilitar el emparejamiento.

Más allá de las características predictoras de cada usuario individual, el sistema evalúa el resultado de la diada mediante sus variables objetivo. Siguiendo con la muestra de los 24 primeros registros analizados, la Figura 4 expone visualmente los campos `compatibility_score`, `compatible` y `relationship_longevity_months` para estas interacciones. En su conjunto, estas tres métricas son las encargadas de definir empíricamente qué tan “satisfactoria” ha resultado la relación, constituyendo la verdad terreno sobre la cual el algoritmo optimizará sus predicciones.

	A	AB	AC	AD
	pair_id	compatibility_score	compatible	relationship_longevity_months
1	1	43.5	0	60
2	2	60.4	0	59
3	3	74.3	1	84
4	4	58.0	0	70
5	5	69.8	1	68
6	6	67.2	1	64
7	7	66.0	1	119
8	8	43.8	0	60
9	9	72.9	1	69
10	10	60.9	0	85
11	11	63.4	0	65
12	12	54.1	0	53
13	13	57.6	0	57
14	14	57.8	0	70
15	15	46.7	0	70
16	16	65.3	1	80
17	17	65.9	1	72
18	18	96.6	1	113
19	19	67.2	1	59
20	20	69.3	1	103
21	21	45.6	0	71
22	22	75.2	1	98
23	23	69.6	1	72
24	24	53.0	0	34

Figure 4: Representación de las variables objetivo que definen el nivel de satisfacción y viabilidad de la relación, correspondientes a los 24 primeros registros del conjunto de datos.

Análisis de los datos

El Análisis Exploratorio de Datos (EDA) se ha enfocado en modelar las dinámicas de interacción intra-pareja para identificar patrones predictivos viables y visualizar la importancia de las diferencias de carácter. Para ello se ejecutó un estudio sistemático apoyado en herramientas de visualización de datos avanzadas.

Distribuciones de las Variables Objetivo

En primera instancia, el análisis univariante comprobó el comportamiento de nuestros objetivos de modelado (*targets*). La Figura 5 expone los resultados gráficos de esta inspección. Se reveló que la variable continua *compatibility_score* se ajusta a una distribución normal asimétrica, centralizada en puntuaciones medias.

Respecto a la etiqueta binaria *compatible*, se detectó un leve desbalance natural en la muestra: un 43% de emparejamientos exitosos frente a un 57% de fracasos (véase el gráfico central de barras). Dado que este desbalance es moderado y refleja proporciones realistas, se concluyó que la aplicación de técnicas algorítmicas de sobremuestreo sintético (como SMOTE) no resultaría estrictamente necesaria para los modelos iniciales basados en ensambles de árboles.




Figure 5: Distribución de las variables objetivo: densidad del *score* de compatibilidad (izquierda), proporción de éxito binario (centro) y distribución de longevidad en meses (derecha).

Afinidad e Ingeniería de Características

El análisis bivariable demostró empíricamente la prevalencia de la **homofilia** como el principal motor de compatibilidad estadística. Es decir, los usuarios tienden a consolidar relaciones exitosas cuando comparten características clave.

Un ejemplo claro de este comportamiento se visualiza en la Figura 6, que muestra la matriz de contingencia normalizada al cruzar los lenguajes del amor del Individuo A y el Individuo B. Las celdas de la diagonal principal (donde ambos comparten el mismo lenguaje) presentan tasas de éxito notablemente superiores, reafirmando empíricamente que compartir el mismo estilo afectivo incrementa la viabilidad matemática de la pareja.



Figure 6: Matriz de contingencia térmica (*Heatmap*): Tasa de compatibilidad porcentual según el cruce de los lenguajes del amor entre ambos individuos.

Con el fin de trasladar estas relaciones geométricas y patrones categóricos a los algoritmos de *Machine Learning*, se ejecutó un proceso profundo de Ingeniería de Características (*Feature Engineering*):

1. **Distancia Euclidiana de Personalidad:** Se procedió a calcular la norma euclidiana vectorial entre el conjunto de rasgos psicológicos (*Big Five* y expresividad emocional) de ambos individuos. Esta transformación matemática consolida múltiples variables en un predictor continuo robusto que penaliza las divergencias extremas de carácter.
2. **Disimilitud Continua:** Se derivaron nuevas métricas calculando las diferencias absolutas (brechas) en atributos numéricos clave, tales como la edad, la ambición profesional y el cronotipo.
3. **Interacciones Categóricas (Efecto Espejo):** Las coincidencias en variables nominales fueron codificadas como indicadores booleanos. El estudio determinó que presentar coincidencias exactas en estas variables incrementa notablemente la probabilidad de éxito. Por ejemplo, compartir el mismo campo profesional (`match_career = 1`) eleva la tasa de compatibilidad promedio hasta el 53.7%.

Las características derivadas se han consolidado en la Tabla 2, clasificadas en función de si su impacto (peso o correlación) resulta positivo o negativo para el algoritmo predictivo.

Característica (Feature)	Impacto	Descripción y Justificación Técnica
<code>match_career</code>	Positivo (+)	Coincidencia exacta en el sector profesional. Correlaciona positivamente con el éxito relacional.
<code>match_love_language</code>	Positivo (+)	Compartir el lenguaje del amor favorece la complementariedad y entendimiento afectivo.
<code>personality_distance</code>	Negativo (-)	Distancia euclidiana en el <i>Big Five</i> . A mayor distancia geométrica, disminuye la probabilidad de éxito.
<code>diff_career_ambition</code>	Negativo (-)	Brecha absoluta en ambición profesional. Las asimetrías severas actúan como factor fuertemente disruptivo.

Table 2: Diccionario de variables interactivas: características con pesos positivos y negativos

Para asegurar una integración óptima en la futura arquitectura de software y prevenir la transferencia indebida de información (*Data Leakage*), estas transformaciones se orquestaron a través de la clase `ColumnTransformer` (perteneciente a la librería *scikit-learn*). Este *pipeline* aplica una estandarización a las variables continuas y una codificación *One-Hot* a las categóricas, dejando el conjunto preparado para la etapa de inferencia y modelado.

Evaluación del rendimiento y Métricas

En el marco de la integración del algoritmo *Cupid* dentro de una arquitectura software real, hemos definido tres métricas operativas principales para evaluar el rendimiento del sistema, diseñadas específicamente para reflejar la experiencia relacional de los usuarios. Las métricas establecidas son:

- Dada una pareja, predecir si son compatibles o no, utilizando la métrica de compatibilidad.
- Dada una pareja, predecir si son compatibles y estimar su tiempo de duración (longevidad).
- Dada una persona, predecir qué otra persona es la más compatible con ella.

A continuación, se formaliza matemáticamente cada uno de estos enfoques:

1. Predicción de Compatibilidad Binaria

Para determinar si dos individuos son compatibles, el sistema genera primero una métrica de compatibilidad continua. Sea u_A y u_B los vectores de características de la Persona A y la Persona B. Definimos la función de compatibilidad del modelo como $S(u_A, u_B) \in [0, 100]$.

La predicción binaria final $\hat{y}$ (compatible o no compatible) se formaliza aplicando un umbral de decisión τ (típicamente establecido en 65, según la distribución empírica del dataset):

$$\hat{y}_{A,B} = \begin{cases} 1 & \text{si } S(u_A, u_B) \geq \tau \\ 0 & \text{si } S(u_A, u_B) < \tau \end{cases} \quad (1)$$

El rendimiento de esta predicción binaria sobre el conjunto de validación se evalúa mediante la Exactitud (*Accuracy*) y el *F1-Score*, contrastando $\hat{y}_{A,B}$ con el éxito real de la pareja, donde el *score* continuo S actúa como el motor discriminador.

2. Estimación de Longevidad Relacional

De forma complementaria a la clasificación de la compatibilidad, el sistema debe ser capaz de estimar la duración temporal de la relación. Definimos la función de estimación de longevidad como $L(u_A, u_B)$, la cual proyecta el tiempo en meses.

La evaluación conjunta asume que la longevidad es un problema de regresión. Para cuantificar la precisión matemática de nuestra estimación respecto a la longevidad real $Y_{A,B}$, se define la función de pérdida mediante el Error Cuadrático Medio (RMSE), penalizando de forma severa las discrepancias extremas en la predicción del tiempo de duración:

$$RMSE = \sqrt{\frac{1}{N} \sum_{i=1}^N \left(Y_{A_i, B_i} - L(u_{A_i}, u_{B_i}) \right)^2} \quad (2)$$

Donde N representa el total de parejas evaluadas. Esta métrica permite comprender el error de la estimación en la misma escala temporal (meses) de la variable objetivo.

3. Recomendación (Matching óptimo)

El objetivo de mayor impacto en el producto no evalúa parejas de forma aislada. En su lugar, dada una persona específica u_A y un conjunto de candidatos disponibles $C = \{c_1, c_2, \dots, c_m\}$, el algoritmo debe **predecir qué persona es la más compatible**, presentando un *ranking* ordenado en orden descendente según $S(u_A, c_j)$.

Para evaluar la calidad de este emparejamiento múltiple, se adoptan métricas del estado del arte de los Sistemas de Recomendación:

- **Mean Reciprocal Rank (MRR):** Cuantifica la rapidez del sistema para ofrecer el emparejamiento óptimo en la interfaz, localizando la posición (o rango) de la *primera* persona verdaderamente compatible recomendada a u_A .

$$MRR = \frac{1}{|U|} \sum_{i=1}^{|U|} \frac{1}{rank_i} \quad (3)$$

Donde $|U|$ es el número total de usuarios consultados, y $rank_i$ representa la posición en la lista del primer candidato compatible. Su maximización asegura que el usuario no tendrá que hacer *scroll* para encontrar a su mejor prospecto.

- **Mean Average Precision (MAP):** Complementando al MRR, el MAP evalúa la calidad global del ranking, calculando la Precisión Media (*AP*) para el top K de personas más compatibles recomendadas:

$$MAP = \frac{1}{|U|} \sum_{u=1}^{|U|} \left(\frac{1}{m_u} \sum_{k=1}^K P_u(k) \cdot rel_u(k) \right) \quad (4)$$

Donde m_u es el número de posibles parejas exitosas para u ; K es el límite de recomendaciones visualizadas; $P_u(k)$ es la precisión hasta la posición k ; y $rel_u(k)$ es 1 si el candidato en la posición k resulta compatible, y 0 en caso contrario.

El planteamiento conjunto de estas tres dimensiones garantiza que la optimización algorítmica responda con exactitud matemática a las necesidades funcionales del producto y la experiencia del usuario.

References

- [DIS26] DISIA-G5, Grupo (2026). *Repositorio del Proyecto DISIA-G5: Cupid Algorithm*. <https://github.com/OscarDominguezOcana/DISIA-G5>. Código fuente, Notebooks de análisis de datos y pipeline de Machine Learning.
- [Ged24] Gedipudi, Likith (2024). *Cupid's Algorithm Dataset*. <https://www.kaggle.com/datasets/likithagedipudi/cupids-algorithm/data>. Accedido en: 2026.
- [Gér19] Géron, Aurélien (2019). *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow: Concepts, Tools, and Techniques to Build Intelligent Systems*. 2nd. O'Reilly Media, Inc.
- [Rak+24] Rakic, Jovana et al. (2024). "The Relation Between Big Five Personality Traits and Relationship Formation Through Matchmaking". In: *Behavioral Sciences* 14.2, p. 112.
- [Uni24] Université Libre de Bruxelles (ULB) (2024). *ULB Project Report Template*. Plantilla de $\text{\LaTeX}$. Utilizada para la maquetación y estructura de la presente memoria.