

CORE-MP: Computación Objetiva de Relaciones Exitosas mediante Modelos Predictivos. Un enfoque data-driven para la evaluación de compatibilidad.

Raúl Bernalte Sánchez

José Manuel Bastante Rodríguez

Óscar Domínguez Ocaña

José Alberto Seco Sánchez-Camacho

Dr. José Antonio De La Torre Las Heras

Dr. Julio Alberto López Gómez

Introducción	3
1 Hito 1: Definición del problema y determinación del alcance	5
1.1 Contexto y definición del problema	5
1.2 Objetivos generales y específicos	7
1.3 Determinación del alcance	8
1.3.1 Planificación	8
1.3.2 Recursos Humanos: asignación de tareas y capacidad	9
1.3.3 Delimitación funcional del sistema	10
1.3.4 Viabilidad y estimación del ROI	10
1.3.5 Valor	11
References	12

List of Tables

List of Figures

1

En el contexto de la **transformación digital de las relaciones interpersonales**, las plataformas de citas y aplicaciones de *matching* han adquirido un papel central en la forma en que las personas establecen conexiones afectivas. En la actualidad, estas plataformas gestionan enormes volúmenes de información sobre preferencias, rasgos de personalidad, características demográficas y patrones de comportamiento. El objetivo fundamental de este ecosistema digital es procesar dicha información para facilitar la formación de **relaciones compatibles y potencialmente duraderas**, actuando como intermediarios algorítmicos en el tejido social.

Tradicionalmente, los sistemas de recomendación en este ámbito se han basado en filtros simples, reglas heurísticas o mecanismos poco transparentes que priorizan coincidencias superficiales (como la edad, la localización geográfica o los intereses básicos). Sin embargo, la compatibilidad relacional es un **fenómeno inherentemente complejo y multidimensional**. El éxito de una relación no se define por la simple superposición de aficiones, sino que depende de una intrincada red de factores psicológicos, valores personales, estilo de vida, ambiciones profesionales y patrones emocionales. La incapacidad de los sistemas tradicionales para capturar esta profundidad suele derivar en recomendaciones irrelevantes, generando frustración y fatiga en el usuario.

En este contexto, surge la necesidad crítica de diseñar **sistemas de inteligencia artificial** capaces de modelar de forma cuantitativa y estructurada la compatibilidad entre individuos. Al integrar múltiples dimensiones personales, estos sistemas pueden descubrir patrones latentes y generar predicciones que sean **consistentes, reproducibles y explicables**. En el delicado ámbito de las relaciones humanas, un sistema de este tipo no solo debe alcanzar un alto rendimiento técnico o estadístico, sino también garantizar su interpretabilidad. Resulta imperativo mantener la coherencia con los principios del dominio relacional, evitando a toda costa funcionar como una "caja negra" que tome decisiones opacas o arbitrarias.

El presente proyecto se fundamenta en el dataset "*Cupid's Algorithm*" [Ged24], un conjunto de datos que contiene información estructurada y enriquecida sobre pares de individuos. Este *dataset* abarca desde

¹El formato y la estructura documental de esta memoria han sido desarrollados utilizando la plantilla oficial de proyectos de la ULB [Uni24].

variables demográficas y profesionales hasta métricas psicométricas profundas, como los rasgos de personalidad basados en el modelo **Big Five** [Rak+24] y los lenguajes del amor, acompañados de indicadores históricos de compatibilidad y duración potencial de la relación. La riqueza de esta información permite abordar el reto desde una **perspectiva supervisada**, formalizando la afinidad relacional como una variable matemática susceptible de ser modelada mediante técnicas avanzadas de aprendizaje automático.

A partir de este marco conceptual, el proyecto no se limita al mero entrenamiento de un modelo predictivo aislado en un entorno académico, sino que adopta una visión integral del **sistema de inteligencia artificial como producto**. Esto implica recorrer, de manera rigurosa, todas las fases del ciclo de vida de un sistema de *Machine Learning* (MLOps): desde la definición formal del problema y la preparación de los datos, pasando por el modelado y la evaluación, hasta culminar en su **integración como servicio de software** y su correspondiente análisis de viabilidad técnica y económica.

De este modo, el objetivo principal del proyecto es diseñar e implementar un **sistema inteligente** capaz de predecir la compatibilidad entre dos individuos de forma completamente objetiva y explicable. Un sistema concebido desde su inicio para ser un componente integrable en una plataforma digital de relaciones, y evaluado no solo a través de métricas de precisión técnica, sino también por su **potencial impacto organizativo, económico y social**.

Hito 1: Definición del problema y determinación del alcance

En este capítulo se detalla la definición del problema seleccionado para la evaluación del proyecto de la asignatura *Desarrollo e Integración de Servicios de IA*, así como la determinación de su alcance.

1.1 Contexto y definición del problema

En el ámbito de las plataformas digitales de relaciones interpersonales, la predicción de compatibilidad entre individuos constituye un problema de **alta relevancia tecnológica, social y económica**. Las aplicaciones de citas modernas gestionan grandes volúmenes de información estructurada sobre los usuarios, incluyendo variables demográficas, profesionales, rasgos de personalidad y preferencias relacionales. A partir de estos datos, los sistemas deben decidir qué perfiles recomendar y qué emparejamientos priorizar.

La compatibilidad relacional es, sin embargo, un **fenómeno inherentemente complejo y multidimensional**. No depende exclusivamente de variables superficiales como la edad o la localización geográfica, sino que está influida por la interacción entre rasgos de personalidad, valores personales, ambiciones profesionales, estilos de comunicación, hábitos cotidianos y expectativas afectivas. Esta naturaleza multifactorial convierte la modelización de la compatibilidad en un problema analítico no trivial.

Tradicionalmente, muchas plataformas han empleado reglas heurísticas o sistemas de filtrado simples basados en coincidencias directas. Estos enfoques presentan limitaciones evidentes: no capturan interacciones complejas, no aprenden patrones implícitos y carecen de transparencia. A diferencia de una regla heurística simple que podría asumir erróneamente que dos personas con la misma *ambición profesional* son compatibles, un modelo de inteligencia artificial puede descubrir **patrones latentes**. Por ejemplo, identificar que dos personas con niveles opuestos de *espontaneidad* pueden ser altamente compatibles si comparten el mismo *lenguaje del amor*. Esta capacidad de capturar interacciones no lineales justifica la necesidad de emplear algoritmos avanzados.

El dataset seleccionado para este proyecto, “*Cupid’s Algorithm*” [Ged24], contiene información estruc-

turada sobre pares de individuos (Person A – Person B), incluyendo:

- **Variables demográficas** (edad, nivel educativo, localización).
- **Variables profesionales** (campo profesional, nivel de ambición).
- **Rasgos de personalidad** basados en el modelo *Big Five*.
- **Variables relacionales** (lenguaje del amor, cronotipo, espontaneidad, expresividad emocional).
- Una variable continua de compatibilidad (*compatibility_score*).
- Una variable binaria de compatibilidad (*compatible*).
- Un indicador de longevidad relacional (*relationship_longe*).

La presencia de estas variables permite abordar el problema desde una **perspectiva supervisada**, donde la compatibilidad observada actúa como señal objetivo para el aprendizaje.

Desde el punto de vista formal, el problema puede plantearse como un problema de **clasificación binaria** [Gér19]. Cada par de individuos queda caracterizado por un conjunto de variables numéricas y categóricas que describen sus atributos individuales. El sistema debe aprender una función:

$$f(X_A, X_B) = P(\text{compatible} = 1)$$

Donde X_A y X_B representan los vectores de características (demográficas y psicológicas) de los individuos A y B.

Alternativamente, el problema puede formularse como una regresión (utilizando *compatibility_score*) o como una predicción de duración (empleando *relationship_longe*). No obstante, en este proyecto se delimita el alcance principal al problema de clasificación binaria, al tratarse de una formulación clara, evaluable y directamente alineada con aplicaciones reales de *matching*.

El sistema no debe limitarse a generar una predicción numérica, sino que debe concebirse como un **sistema de inteligencia artificial integrable** en un entorno software real. Esto implica que el modelo debe ser reproducible, evaluable mediante métricas adecuadas y *potencialmente explicable*, de manera que las decisiones puedan ser comprendidas por responsables de producto y desarrolladores de la plataforma.

En consecuencia, el problema queda claramente delimitado: a partir de datos estructurados que describen características personales, profesionales y psicológicas de dos individuos, se busca diseñar un sistema de inteligencia artificial capaz de predecir de forma **objetiva, consistente y explicable** su compatibilidad relacional, concebido como un componente integrable dentro de una arquitectura software más amplia.

1.2 Objetivos generales y específicos

El problema que se aborda en este proyecto puede formularse de la siguiente manera: ¿Cómo diseñar un sistema de inteligencia artificial capaz de predecir de forma objetiva, consistente y explicable la compatibilidad entre dos individuos, a partir de variables demográficas, profesionales y de personalidad, garantizando su integración como servicio software en una plataforma digital de relaciones?

Esta formulación no se limita a la obtención de buenas métricas técnicas, sino que incorpora explícitamente la dimensión de **sistema IA como producto**, concebido para integrarse en un entorno real, evolucionar en el tiempo y aportar valor a distintos *stakeholders*.

Para dar respuesta a esta pregunta, se establece como **objetivo general** del proyecto diseñar, implementar y validar un sistema de inteligencia artificial capaz de predecir la compatibilidad relacional entre dos individuos utilizando datos estructurados, garantizando su integración en una arquitectura software real y su funcionamiento fiable, explicable y reproducible a lo largo del tiempo.

Para alcanzar el objetivo general propuesto, se establecen los siguientes **objetivos específicos**:

- **Analizar y formalizar** el concepto de compatibilidad relacional desde una perspectiva cuantitativa y multidimensional, identificando las variables más relevantes.
- **Seleccionar y procesar** los datos del dataset *Cupid's Algorithm*, incluyendo limpieza, codificación y construcción de variables derivadas (similitud o distancia entre perfiles).
- **Diseñar y entrenar** modelos de aprendizaje automático supervisado que permitan predecir la variable binaria compatible, evaluando distintas aproximaciones metodológicas.
- **Evaluar el rendimiento** de los modelos mediante métricas técnicas adecuadas para clasificación binaria (Accuracy, Precision, Recall, F1-score, ROC-AUC), analizando su comportamiento desde una perspectiva de dominio.
- **Incorporar mecanismos de explicabilidad**, que permitan interpretar la influencia relativa de las distintas variables y facilitar su comprensión por parte de perfiles no técnicos.
- **Diseñar el sistema como un servicio integrable**, desarrollando una API REST que permita realizar predicciones de compatibilidad a partir de nuevos pares de individuos.
- **Analizar la viabilidad** económica y organizativa del sistema, estimando costes de desarrollo y potencial retorno de la inversión (ROI).

- **Diseñar el sistema con una arquitectura extensible** que permita, en iteraciones futuras, transicionar de una clasificación binaria a un motor de recomendación Top-K o a la predicción de longevidad relacional.

De este modo, el proyecto no se concibe como un simple ejercicio de modelado predictivo, sino como el desarrollo completo de un **sistema de inteligencia artificial entendido como producto tecnológico**, recorriendo todas las fases de su ciclo de vida.

1.3 Determinación del alcance

En esta sección se define el alcance del proyecto a desarrollar en la asignatura, prestando especial atención a los componentes clave que delimitan un sistema de inteligencia artificial concebido como producto: **planificación temporal, organización del equipo, viabilidad económica y valor generado**.

El alcance no solo determina qué se va a desarrollar, sino también qué queda explícitamente fuera del proyecto, con el fin de garantizar su viabilidad dentro del marco temporal y evitar una expansión descontrolada de requisitos.

1.3.1 Planificación

El desarrollo del proyecto se ha estructurado en un horizonte temporal estimado de **ocho semanas**, concebido como un flujo de trabajo continuo que abarca todas las fases del ciclo de vida de un sistema de *Machine Learning*. Durante las dos primeras semanas, el equipo se centrará en el **análisis y comprensión del problema**. Esta fase inicial es crítica e implica un estudio detallado del dataset *Cupid's Algorithm*, la realización de un análisis exploratorio de las variables disponibles y la formalización definitiva del reto como un problema de clasificación binaria.

A continuación, las semanas tercera y cuarta se destinarán a la **preparación y transformación de los datos**. En este periodo se llevarán a cabo tareas fundamentales como la limpieza del conjunto de datos, el tratamiento de valores nulos, la codificación de las variables categóricas y, de forma muy destacada, la ingeniería de características para construir variables derivadas que representen similitudes, diferencias y distancias entre los perfiles. Esta fase concluirá con la división técnica del dataset en conjuntos de entrenamiento y validación.

Posteriormente, el proyecto entrará en su núcleo analítico durante las semanas quinta y sexta, enfocadas en el **modelado y la evaluación**. Durante esta etapa, se entrenarán distintos modelos de aprendizaje supervisado, se compararán sus métricas de rendimiento y se seleccionará el modelo final. Además, se

dedicará un esfuerzo específico al análisis de la explicabilidad del sistema, garantizando que las predicciones no provengan de una caja negra. Una vez consolidado el modelo, la séptima semana marcará la transición hacia la **integración como servicio**. El equipo procederá a la serialización del modelo entrenado y al desarrollo de una API REST que permita realizar predicciones en tiempo real, finalizando con pruebas funcionales del sistema.

Finalmente, la octava semana estará dedicada a la **validación y el análisis de valor**. En esta última etapa se evaluará el sistema en su conjunto, se realizará el análisis de viabilidad económica y retorno de inversión (ROI), y se consolidará la redacción de la documentación final del proyecto, asegurando que el producto técnico cumpla con los estándares académicos y profesionales exigidos.

1.3.2 Recursos Humanos: asignación de tareas y capacidad

El desarrollo del sistema **CORE-MP** se lleva a cabo mediante la colaboración de un equipo técnico formado por cuatro integrantes. Para garantizar el éxito del proyecto y simular un entorno profesional realista, se han definido perfiles con responsabilidades claramente delimitadas, alineadas con los roles habituales en el desarrollo de productos basados en inteligencia artificial.

Persona 1. Rol principal: Product Manager y Analista de Negocio. Dado que el equipo no cuenta de forma nativa con un experto de dominio puro en psicología relacional, este integrante asume un rol híbrido fundamental. Su responsabilidad es actuar como puente entre el desarrollo técnico y los objetivos funcionales del proyecto. Se encarga de comprender a fondo la naturaleza de los datos disponibles, definir qué variables tienen sentido lógico agrupar o comparar, y establecer los umbrales de éxito del sistema. Además, evalúa si los resultados del modelo y su explicabilidad son coherentes y aportan valor real para una hipotética plataforma de *matching*, validando el producto desde la perspectiva del usuario final.

Persona 2. Rol principal: Analista de Datos (Data Analyst / Data Engineer). Este integrante asume la responsabilidad crítica del procesamiento, limpieza y transformación de los datos procedentes del dataset original. Su trabajo abarca desde la exploración estadística inicial hasta la generación de un conjunto de datos consistente y estructurado, aplicando técnicas de ingeniería de características para crear métricas de similitud entre los perfiles. Este rol es la base sobre la que se asienta todo el proyecto, ya que la calidad de las predicciones dependerá directamente de la robustez de los datos preparados en esta fase.

Persona 3. Rol principal: Ingeniero de Machine Learning (ML Engineer). Este perfil es el responsable del diseño metodológico del sistema desde el punto de vista del modelado predictivo. Sus tareas incluyen la selección de los algoritmos de clasificación más adecuados, el entrenamiento de los modelos, el ajuste de hiperparámetros y la evaluación exhaustiva mediante métricas técnicas (como F1-Score o ROC-AUC).

Asimismo, asume la responsabilidad de aplicar técnicas de interpretabilidad al modelo seleccionado, facilitando que el resto del equipo comprenda cómo interactúan los rasgos de personalidad en las predicciones finales.

Persona 4. Rol principal: Ingeniero de Integración y MLOps (ML Systems Engineer). Su responsabilidad principal es garantizar que el proyecto no se limite a un experimento aislado en un cuaderno de programación, sino que se convierta en un producto de software funcional. Sus labores incluyen la serialización y versionado del modelo entrenado, así como el diseño y desarrollo de la API REST que servirá las predicciones. Este integrante se asegura de que la arquitectura del sistema sea robusta y esté preparada para recibir peticiones de emparejamiento como un microservicio independiente.

Esta estructura organizativa garantiza que se cubran todas las necesidades del ciclo de vida de un sistema de IA concebido como producto, desde la conceptualización del negocio hasta su despliegue técnico.

1.3.3 Delimitación funcional del sistema

El alcance funcional del proyecto se limita a:

- Predicción binaria de compatibilidad (*compatible*).
- Uso exclusivo del dataset *Cupid's Algorithm*.
- Desarrollo de una API REST básica para predicción y evaluación *offline*.

Quedan explícitamente fuera del alcance:

- Desarrollo de una plataforma web completa o integración con bases de datos reales en producción.
- Implementación de un sistema de recomendación Top-K a gran escala.
- Despliegue en entorno *cloud* productivo final.

1.3.4 Viabilidad y estimación del ROI

Para estimar la viabilidad económica del sistema se plantean los siguientes supuestos:

- Equipo técnico: 4 personas (desarrollo).
- Dedicación media: 8 horas semanales por persona durante 8 semanas.
- Coste medio por hora: 40 €.

Horas y coste total estimados:

$$\text{Horas totales} = 4 \text{ personas} \times 8 \text{ h/semana} \times 8 \text{ semanas} = 256 \text{ horas}$$

$$\text{Coste total} = 256 \text{ horas} \times 40 \text{ €/hora} = 10.240 \text{ €}$$

Un sistema de predicción de compatibilidad puede generar beneficios mediante el incremento de emparejamientos exitosos y la reducción del abandono de usuarios. Si el sistema generara un beneficio acumulado conservador de 15.000 € en un periodo de uso prolongado, el retorno de la inversión sería:

$$ROI = \frac{\text{Beneficio} - \text{Coste}}{\text{Coste}} = \frac{15000 - 10240}{10240} = 0.46$$

Es decir, un **46% de retorno estimado**, lo que indica una clara viabilidad económica.

1.3.5 Valor

El valor del sistema **CORE-MP** se analiza desde múltiples dimensiones:

- **Valor de Negocio / Relacional:** Generación de emparejamientos de alta calidad que justifican modelos de suscripción *Premium* y reducen la fatiga del usuario (*swipe burnout*), aumentando el ciclo de vida del cliente.
- **Valor tecnológico:** Formalización de la compatibilidad como problema supervisado mediante un modelo reproducible, explicable y con arquitectura de microservicio.
- **Valor organizativo:** Sistema escalable que sienta las bases para futuros motores de recomendación más avanzados.
- **Valor social:** Mayor transparencia en el proceso de *matching*, reducción de sesgos o decisiones arbitrarias y mejora sustancial en la confianza del usuario.

Con esta delimitación, el proyecto se concibe como el desarrollo completo de un sistema de inteligencia artificial entendido como producto tecnológico, garantizando su viabilidad dentro del marco académico.

References

- [Ged24] Gedipudi, Likith (2024). *Cupid's Algorithm Dataset*. <https://www.kaggle.com/datasets/likithagedipudi/cupids-algorithm/data>. Accedido en: 2026.
- [Gér19] Géron, Aurélien (2019). *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow: Concepts, Tools, and Techniques to Build Intelligent Systems*. 2nd. O'Reilly Media, Inc.
- [Rak+24] Rakic, Jovana et al. (2024). "The Relation Between Big Five Personality Traits and Relationship Formation Through Matchmaking". In: *Behavioral Sciences* 14.2, p. 112.
- [Uni24] Université Libre de Bruxelles (ULB) (2024). *ULB Project Report Template*. Plantilla de $\text{\LaTeX}$. Utilizada para la maquetación y estructura de la presente memoria.